

Dokumentacja Specyfikacji Wymagań

System klasyfikacji artykułów BBC

Wprowadzenie

Niniejszy dokument opisuje specyfikację wymagań dla systemu służącego do automatycznej analizy i klasyfikacji artykułów prasowych BBC. System umożliwia import danych tekstowych, ich przygotowanie do analizy, identyfikację istotnych cech dokumentów oraz przypisywanie artykułów do kategorii tematycznych. Wyniki działania systemu są prezentowane w formie raportu HTML zawierającego zestawienia, wizualizacje oraz ocenę jakości klasyfikacji.

Cele systemu

- **Wczytanie i przygotowanie danych:**
 - Umożliwienie importu danych tekstowych wraz z przypisanymi kategoriami tematycznymi zapisanych w pliku CSV.
 - Zapewnienie kompletności i poprawności danych wejściowych przed rozpoczęciem procesu analizy.
- **Przetwarzanie i oczyszczanie tekstu:**
 - Umożliwienie organizacji danych tekstowych w postaci korpusu dokumentów przeznaczonego do dalszej analizy.
 - Umożliwienie automatycznego oczyszczania tekstu z elementów nieistotnych dla analizy, takich jak znaki specjalne, liczby, interpunkcja, nadmiarowe odstępki, adresy URL oraz znaczniki techniczne.
 - Umożliwienie eliminacji słów o niskiej wartości informacyjnej w celu poprawy jakości analizy tekstu.
 - Umożliwienie normalizacji słownictwa poprzez redukcję różnych form wyrazów do wspólnej postaci.
- **Eksploracyjna analiza danych (EDA):**
 - Umożliwienie identyfikacji najczęściej występujących oraz najbardziej charakterystycznych terminów w analizowanym zbiorze dokumentów.
 - Umożliwienie oceny istotności słów w poszczególnych dokumentach względem całego analizowanego zbioru.
 - Umożliwienie wizualizacji słownictwa charakterystycznego dla całego zbioru dokumentów oraz poszczególnych kategorii tematycznych.
- **Klasyfikacja nadzorowana SVM:**
 - Ograniczenie liczby cech wykorzystywanych w analizie w celu zwiększenia efektywności procesu klasyfikacji.
 - Umożliwienie automatycznej klasyfikacji artykułów do odpowiednich kategorii tematycznych oraz oceny skuteczności klasyfikacji.

- Umożliwienie porównania różnych metod przygotowania danych treningowych i testowych.
- Umożliwienie oceny jakości działania modelu klasyfikacyjnego przy użyciu standardowych miar skuteczności.
- **Wizualizacja i raportowanie:**
 - Zapewnienie czytelnej wizualizacji wyników analizy i klasyfikacji.
 - Umożliwienie automatycznego generowania raportu HTML zawierającego wyniki analizy, wizualizacje oraz podsumowanie procesu klasyfikacji.

3. Wymagania funkcjonalne

- **Import danych:** System powinien umożliwiać wczytanie danych tekstowych oraz przypisanych im kategorii z pliku CSV.
- **Walidacja danych:** System powinien sprawdzać poprawność i kompletność danych wejściowych przed rozpoczęciem analizy.
- **Tworzenie korpusu dokumentów:** System powinien umożliwiać organizację zaimportowanych tekstów w postaci korpusu dokumentów.
- **Oczyszczanie tekstu:** System powinien usuwać elementy nieistotne dla analizy, takie jak znaki specjalne, liczby, interpunkcja, adresy URL oraz nadmiarowe odstępy.
- **Normalizacja tekstu:** System powinien umożliwiać ujednolicenie tekstu poprzez zamianę liter na małe oraz sprowadzenie różnych form wyrazów do wspólnej postaci.
- **Usuwanie słów nieistotnych:** System powinien umożliwiać eliminację słów o niskiej wartości informacyjnej.
- **Tworzenie reprezentacji dokumentów:** System powinien przekształcać dokumenty tekstowe do postaci umożliwiającej dalszą analizę komputerową.
- **Analiza istotności słów:** System powinien umożliwiać określanie znaczenia poszczególnych słów w dokumentach względem całego zbioru danych.
- **Redukcja liczby cech:** System powinien ograniczać liczbę analizowanych cech w celu zwiększenia efektywności klasyfikacji.
- **Analiza częstości słów:** System powinien identyfikować najczęściej występujące słowa w całym zbiorze oraz w poszczególnych kategoriach.
- **Wizualizacja danych:** System powinien generować wizualizacje przedstawiające najważniejsze słowa oraz wyniki analizy tekstu.
- **Podział danych:** System powinien umożliwiać podział danych na zbiory treningowe i testowe.
- **Klasyfikacja artykułów:** System powinien automatycznie przypisywać artykuły do odpowiednich kategorii tematycznych na podstawie ich treści.
- **Ocena jakości klasyfikacji:** System powinien umożliwiać ocenę skuteczności klasyfikacji przy użyciu standardowych miar jakości.
- **Generowanie raportu:** System powinien umożliwiać utworzenie raportu zawierającego wyniki analizy, wizualizacje oraz ocenę modelu klasyfikacyjnego.

4. Wymagania нефункционалне

- **Wydajność:** System powinien przetwarzać dane w czasie umożliwiającym komfortową pracę użytkownika.
- **Stabilność:** System powinien działać poprawnie dla wszystkich poprawnie przygotowanych danych wejściowych.
- **Odtwarzalność wyników:** System powinien zapewniać możliwość uzyskania tych samych wyników dla tych samych danych wejściowych.
- **Kompatybilność:** System powinien być możliwy do uruchomienia w środowisku RStudio na systemach Windows, macOS oraz Linux.
- **Czytelność kodu:** Kod źródłowy powinien być uporządkowany, udokumentowany i podzielony na logiczne sekcje.
- **Użyteczność raportu:** Raport wynikowy powinien być czytelny i umożliwiać łatwą interpretację wyników.
- **Przenośność:** System powinien być możliwy do uruchomienia na różnych komputerach bez konieczności modyfikowania kodu źródłowego.
- **Możliwość rozbudowy:** System powinien umożliwiać łatwe rozszerzanie o nowe metody analizy tekstu i klasyfikacji.

5. Interfejsy użytkownika

- **Wejście:**
 - Lokalny, tabelaryczny plik danych Artykuly_final.csv umieszczony w katalogu roboczym R (ścieżka relatywna).
 - Plik zawiera dwie kolumny: tekst (treść artykułu w języku angielskim) oraz kategoria (etykieta klasy tematycznej).
- **Wyjście:**
 - Konsola CLI środowiska RStudio wyświetlająca struktury korpusu, wymiary macierzy, macierze pomyłek oraz wartości metryk Accuracy.
 - Wykresy w panelu Plots: globalne chmury słów (TDM i TF-IDF), chmury słów per kategoria, wykresy słupkowe metryk Precision/Recall/Specificity/F1-Score.
 - Raport menedżerski w formacie HTML generowany za pomocą silnika RMarkdown, oparty na czytelnym motywie readable, zawierający automatyczny pływający spis treści (toc_float) oraz globalną funkcję zwijania i rozwijania bloków kodu (code_folding: show).

Plik CSV



Przetwarzanie tekstu



Analiza cech



Klasyfikacja artykułów



Raport HTML

6. Wymagania dotyczące danych i słownictwo dokumentacji

- **Wymagania dotyczące danych:**

- System przetwarza i analizuje wyłącznie teksty artykułów napisane w języku angielskim.
- System zakłada, że kolumna kategoria zawiera etykiety tekstowe jednoznacznie przypisujące każdy artykuł do jednej kategorii tematycznej.
- Plik CSV musi używać średnika jako separatora pól i być zapisany w kodowaniu kompatybilnym z UTF-8.

- **Słownictwo dokumentacji:**

- VCorpus (Volatile Corpus): ulotny korpus tekstowy, wbudowana w pakiet tm struktura danych przechowująca zbiór dokumentów w pamięci RAM komputera.
- TDM (TermDocumentMatrix): macierz matematyczna, w której wiersze reprezentują unikalne słowa (termy), kolumny to poszczególne dokumenty, a wartości w komórkach określają częstość danego słowa w danym artykule.
- TF-IDF: statystyczna miara ważenia tekstu, która ocenia znaczenie słowa w kontekście całej bazy artykułów (promuje słowa unikalne dla danej kategorii, obniżając wagę słów powszechnych).
- Stemming: proces sprowadzania słów do ich rdzenia morfologicznego przy użyciu algorytmu Portera (np. running, runs, ran → run).
- Stopwords: słowa o niskiej wartości informacyjnej, usuwane w procesie preprocessingu (np. the, and, for, is, was).
- Bag of Words (BoW): model reprezentacji tekstu, w którym każdy dokument opisywany jest jako wektor częstości słów, bez uwzględnienia ich kolejności.
- SVM (Support Vector Machine): algorytm uczenia maszynowego nadzorowanego służący do klasyfikacji danych.
- Podział losowy: losowy podział zbioru danych na treningowy (80%) i testowy (20%) bez zachowania proporcji klas.
- Podział stratyfikowany: podział zbioru danych zachowujący proporcje klas w obu zbiorach, realizowany przez createDataPartition() z pakietu caret.
- Confusion Matrix (macierz pomyłek): tabela przedstawiająca zestawienie predykowanych klas z klasami rzeczywistymi.
- Precision: precyzja – $TP / (TP + FP)$. Jaki odsetek artykułów przypisanych do danej kategorii rzeczywiście do niej należy.
- Recall: czułość – $TP / (TP + FN)$. Jaki odsetek artykułów z danej kategorii został poprawnie wykryty.
- F1-Score: harmoniczna średnia Precision i Recall, ogólna miara jakości klasyfikacji dla danej klasy.
- Reproducible Research: podejście badawcze zapewniające pełną odtwarzalność wyników przez dostarczenie kodu źródłowego i danych wejściowych.

7. Przypadki użycia (use cases)

- **Użytkownik:**

- Umieszcza plik Artykuly_final.csv w katalogu roboczym R.
- Uruchamia procedurę automatycznego renderowania raportu (Compile Report w RStudio).

- Analizuje końcowy, sformatowany dokument HTML, filtrując widoczność kodu źródłowego według potrzeb.
- **Skrypt/system:**
 - Wczytuje dane wejściowe z pliku CSV i tworzy obiekt VCorpus z kolumny tekst.
 - Czyści dane tekstowe z adresów URL, znaków specjalnych i artefaktów kodowania za pomocą potoków `tm_map` i `gsub`.
 - Filtruje słownictwo ze standardowych oraz dedykowanych stop-słów i przeprowadza stemming.
 - Konstruuje macierze TDM i TDM-TFIDF oraz redukuje ich wymiar poprzez usuwanie słów rzadkich.
 - Generuje globalne i per-kategoryjne chmury słów oraz wyświetla top 10 słów dla każdej kategorii.
 - Trenuje dwa modele SVM (podział losowy i stratyfikowany) i oblicza metryki jakości klasyfikacji.
 - Generuje wykresy słupkowe metryk i kompiluje estetyczny plik raportu HTML.

Testowe przypadki użycia:

- Test kompletności pliku: Uruchomienie skryptu przy obecnym pliku `Artykuly_final.csv` w celu weryfikacji poprawnego przejścia całego potoku analitycznego bez błędów.
- Test stabilności losowej: Dwukrotne uruchomienie skryptu od zera w celu sprawdzenia, czy wygenerowane chmury słów, wykresy metryk SVM oraz macierze pomyłek są idealnie tożsame (weryfikacja działania `set.seed(123)`).
- Test czyszczenia znaków specjalnych: Weryfikacja, czy po przejściu procedur preprocessingowych z artykułów całkowicie zniknęły linki URL, znaki interpunkcyjne oraz pozostałości błędnego kodowania.
- Test redukcji wymiarowości: Sprawdzenie, czy po wywołaniu `removeSparseTerms(tdm_tfidf, 0.99)` liczba cech (słów) w macierzy jest znacząco mniejsza niż w macierzy wyjściowej.
- Test podziału stratyfikowanego: Weryfikacja, czy proporcje kategorii w zbiorze treningowym i testowym są zbliżone do proporcji w pełnym zbiorze danych.

8. Scenariusze użytkownika (user stories)

Scenariusz 1: Automatyczna klasyfikacja artykułów do kategorii tematycznych

- **Jako:** Redaktor serwisu informacyjnego.
- **Chcę:** Automatycznie przypisywać nowe artykuły prasowe do kategorii tematycznych (sport, biznes, polityka, technologia, rozrywka) na podstawie ich treści.
- **Aby:** Przyspieszyć kategoryzację dużych zbiorów artykułów bez konieczności ręcznego przeglądania każdego tekstu.

Kryteria akceptacji:

- Skrypt poprawnie wczytuje dane i buduje model SVM dla obu metod podziału danych.
- System generuje confusion matrix i oblicza wartości Precision, Recall i F1-Score dla każdej z kategorii.

- Wyniki wizualizowane są na czytelnych wykresach słupkowych z podziałem na metryki (facet_wrap).

Scenariusz 2: Eksploracja słownictwa charakterystycznego dla kategorii

- **Jako:** Analityk danych.
- **Chcę:** Zobaczyć chmury słów i rankingi top 10 słów osobno dla każdej kategorii tematycznej, z zastosowaniem wag TF-IDF.
- **Aby:** Zrozumieć, jakie słownictwo jest charakterystyczne dla artykułów sportowych, biznesowych i politycznych, oraz zweryfikować jakość preprocessingu.

Kryteria akceptacji:

- System generuje układ 6 chmur słów (2x3) z tytułami odpowiadającymi nazwie kategorii.
- Skrypt wyświetla tabelę top 10 słów z wagami TF-IDF dla każdej z kategorii.
- Słowa w chmurach są rzeczywiście tematycznie powiązane z daną kategorią (brak ogólnych stopwords).

Scenariusz 3: Sprawne uruchomienie i przegląd techniczny projektu

- **Jako:** Wykładowca / Audytor kodu.
- **Chcę:** Pobrać skrypt, umieścić plik CSV w folderze i uruchomić proces kompilacji raportu, mając możliwość wygodnego zwijania sekcji z kodem źródłowym podczas analizy wyników.
- **Aby:** Sprawnie ocenić poprawność implementacji algorytmów tekstowych, jakość wygenerowanych wizualizacji oraz poprawność obliczonych metryk SVM bez zaburzania estetyki dokumentu nadmiarem kodu.

Kryteria akceptacji:

- Skrypt używa relatywnego odwołania do pliku danych ('Artykuly_final.csv'), co pozwala na uruchomienie na dowolnym komputerze.
- Raport HTML ładuje się z motywem readable oraz posiada działający, pływający spis treści (toc_float: collapsed: false).
- Każdy blok kodu R w wygenerowanym dokumencie HTML posiada działający przycisk Hide/Show (code_folding: show).
- Wyniki dla podziału losowego i stratyfikowanego są wyraźnie odseparowane w strukturze raportu.